DiseÃ±o y OptimizaciÃ³n de una CNN para ClasificaciÃ³n de ImÃ¡genes Complejas

ClasificaciÃ³n de dÃgitos de nÃºmeros de casa (SVHN)

Informe de la actividad

Ramos Ticahuanca, Gianella Alexandra
SuÃ¡rez Condori, Juan Gabriel
Del Ã■guila GarcÃa, JesÃºs
Mendoza Torres, Lincol J.

VersiÃ³n del modelo: 1.0.0
Fecha: 19/10/2026
Repositorio: https://github.com/Abrilskop/proyectoiafino

1. Contexto de la misiÃ³n

Actuamos como ingenieros de visiÃ³n artificial para una startup de logÃstica. El objetivo es una Red Neuronal Convolucional (CNN) capaz de clasificar con alta precisiÃ³n imÃ¡genes de nÃºmeros de casa del dataset **SVHN** (Street View House Numbers, 32Ã—32 RGB, 10 clases), enfrentando problemas reales como el sobreajuste y la variabilidad de los datos.

2. Fase A â€" PreparaciÃ³n y preprocesamiento

Los datos se descargan con `torchvision.datasets.SVHN` y se normalizan con la media/desviaciÃ³n calculadas sobre el propio dataset. Se usa un subconjunto del 20 % del entrenamiento (CPU) para iterar rÃ¡pido, manteniendo el test completo (26 032 imÃ¡genes).

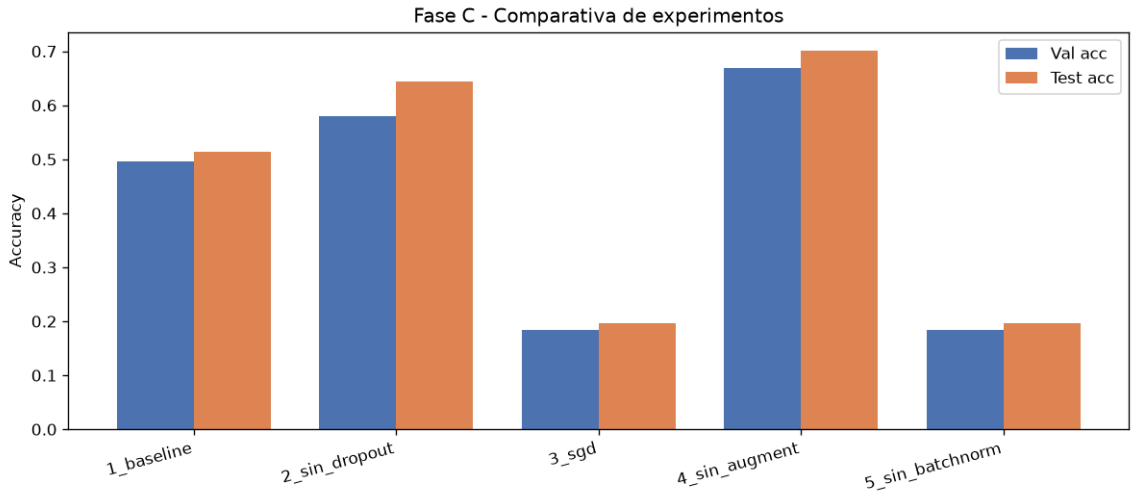
3. Fase B â€" Arquitectura del modelo base

La CNN (`src/models/cnn.py`) consta de 3 bloques convolucionales. Cada bloque usa convoluciones de **3Ã—3, stride 1, padding 1** con activaciÃ³n **ReLU**, seguido de **MaxPooling 2Ã—2** que reduce la dimensiÃ³n espacial (32â†'16â†'8â†'4). Se incluye **Batch Normalization** (innovaciÃ³n) y **Dropout** en el clasificador. La salida usa **Softmax** multiclase (10 neuronas) para obtener probabilidades por dÃgito.

4. Fase C â€" ExperimentaciÃ³n

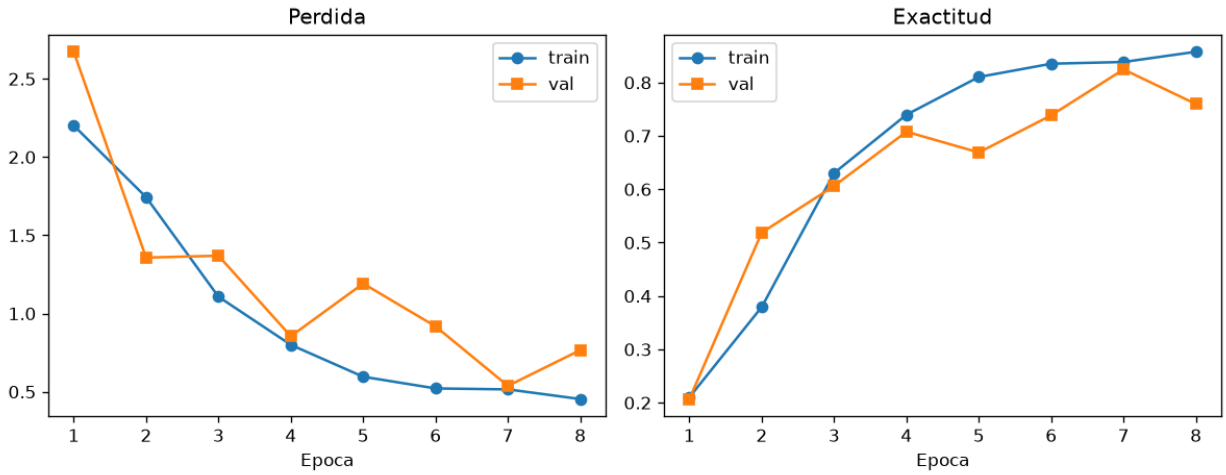
Se parte de un **baseline** y se modifica un factor por corrida para aislar su efecto: (1) baseline, (2) sin Dropout, (3) SGD en lugar de Adam, (4) sin Data Augmentation, (5) sin Batch Normalization.

Experimento	Dropout	Optimizador	Aug (rot/zoom)	BatchNorm	Train acc	Val acc	Test acc	Gap (overfit)
1_baseline	si	ADAM	si	si	0.436	0.497	0.515	-0.060
2_sin_dropout	no	ADAM	si	si	0.618	0.580	0.643	+0.039
3_sgd	si	SGD	si	si	0.183	0.184	0.196	-0.000
4_sin_augment	si	ADAM	no	si	0.649	0.669	0.701	-0.020
5_sin_batchnorm	si	ADAM	si	no	0.192	0.184	0.196	+0.008



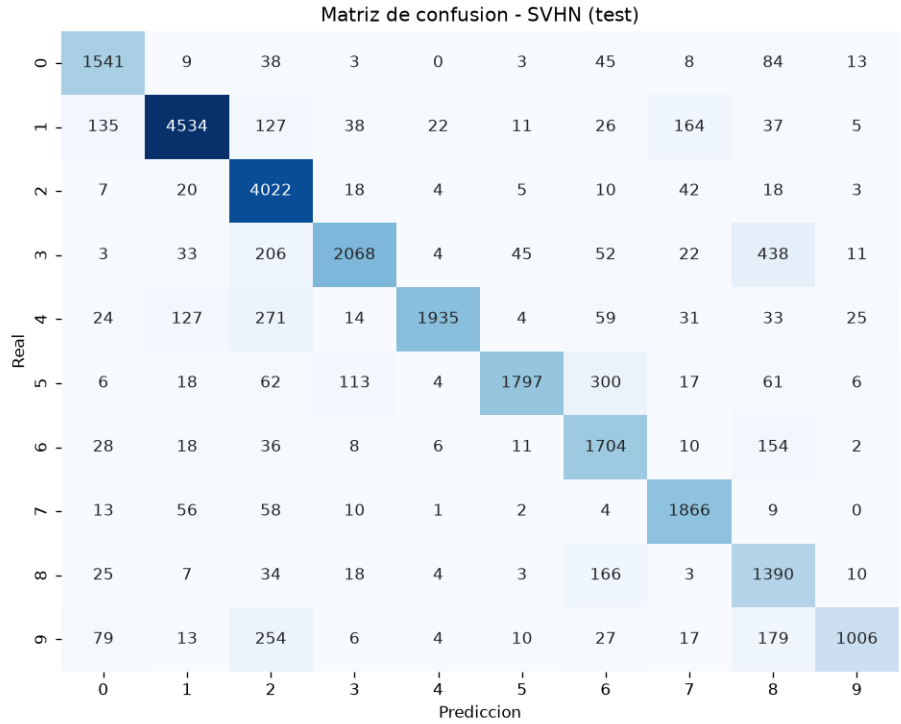
5. Curvas de Loss y Accuracy (train vs validaciÃ³n)

La diferencia entre la curva de entrenamiento y la de validaciÃ³n es la seÃ±al del sobreajuste. Un *gap* creciente (trainâ†‘, valâ†“) indica que el modelo memoriza el train en vez de generalizar.



6. Matriz de confusiÃ³n

Permite ver quÃ© clases se confunden mÃ¡s. Las confusiones suelen darse entre dÃgitos visualmente parecidos (p. ej. 3/8, 4/9, 5/6).



Accuracy final (modelo completo, test): 0.8399 | **macro-F1:** 0.824 | **KPI â‰¥ 0.8:** cumplido

7. CÃ¡lculo de la precisiÃ³n final (Accuracy)

La exactitud se define como la fracciÃ³n de predicciones correctas:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} = \frac{\text{aciertos}}{\text{total}}$$

Con 26032 imÃ¡genes de test y accuracy 0.8399, el nÃºmero de aciertos es â‰ˆ 21864 (21864/26032).

8. AnÃ¡lisis del sobreajuste y conclusiones

Â¿Por quÃ© ocurre el overfitting? Con pocas muestras la red aprende el ruido del train. La brecha entre accuracy de train y de validaciÃ³n (columna *Gap* de la tabla) mide este efecto: a mayor *gap*, mÃ¡s sobreajuste.

RegularizaciÃ³n (Dropout): comparar el baseline con Â«sin DropoutÂ» muestra cÃ³mo el Dropout reduce la brecha train/validaciÃ³n y mejora la generalizaciÃ³n.

Data Augmentation (rotaciÃ³n + zoom): aumenta la variabilidad artificial del train y suele mejorar la accuracy de validaciÃ³n. Observar la diferencia entre el baseline y Â«sin AugmentationÂ».

OptimizaciÃ³n (Adam vs SGD): Adam converge mucho mÃ¡s rÃ¡pido con esta tasa de aprendizaje; el SGD sin ajustar la tasa apenas aprende en pocas Ã©pocas, evidenciando la importancia del optimizador.

InnovaciÃ³n (Batch Normalization): al retirarla, el entrenamiento se estanca; BatchNorm estabiliza y acelera la convergencia.

ConclusiÃ³n: la CNN con Conv 3Ã—3 + MaxPooling + BatchNorm + Dropout + Data Augmentation entrenada con Adam es la configuraciÃ³n mÃ¡s robusta, alcanzando un accuracy de test de 0.8399 sobre el conjunto completo, cumpliendo el KPI (â‰¥ 0.80).